

WaterChat 简介

一. 愿景

每一个人都可以简单地使用 AI 大模型。

二. 特性

1. 纯本地运行。非常适合在网络受限环境使用！
2. 隐私。开源模型；开源应用；100% 离线安装、运行和使用。您的隐私您掌控！
3. 小巧。只需一点耐心，普通电脑也可以运行！
4. 广泛。在 Windows 和 Mac 电脑上皆可使用！

三. 通过 UI 界面新增 AI 模型

注意：只能够支持 GGUF 类型的 AI 模型。


1. 假设你需要添加的 AI 模型为 Qwen3.5-2B-GGUF，那么请在你的电脑本地新建文件夹并命名为：Qwen3.5-2B-GGUF。然后到 huggingface 等网站将 Qwen3.5-2B-GGUF 的全部模型文件下载并且放到刚刚新建的文件夹当中。
2. 打开应用，来到帮助页面。点击“增加 AI 模型”按钮。




3. 应用打开弹窗。点击“选择主文件（GGUF）”按钮。




4. 选择你的 AI 模型的 XXXX.gguf 主文件。



5. 确认信息无误之后，点击“确认增加”按钮。



6. 添加信息弹窗弹出，添加 AI 模型完毕。请退出应用再次打开即可。




四. 自行增加 AI 模型（手动）

1. 本应用应当都能够支持阿里巴巴通义千问 Qwen3 **GGUF** 类型的 AI 文本对话大模型。


2. 操作步骤：

- 假设你要新增 Qwen3 **GGUF 类型** 的 Qwen3-1.7B-GGUF 的 AI 模型。
- 请在你的电脑资源管理器（Mac 电脑叫做“访达”）中找到“下载”文件夹，在“下载”文件

加当中应该会有“waterchat”，这时候依次打开以下文件夹“waterchat/resources/models”，models 文件夹里面应当已经有 Qwen3-0.6B-GGUF（本应用的模型）文件夹了，这时请新建名称为：Qwen3-1.7B-GGUF 文件夹。




上图：windows 中的示意图



上图：Mac 中的示意图

c) 下载 Qwen3-1.7B-GGUF 的模型参数文件。Qwen3-1.7B-GGUF 的模型参数文件的链接是：<https://huggingface.co/Qwen/Qwen3-1.7B-GGUF/tree/main>。如果是增加 Qwen3 其他的模型，也请自行在 hugging face 网站找到你想要增加的 Qwen3 GGUF 的模型参数文件。



d) 将上一步骤中所有的文件下载，然后将所有的下载的文件保存到 b) 中新建的文件夹（Qwen3-1.7B-GGUF）当中。注意：如果一个模型内存在多个模型分类时，你可以尝试仅下载对应模型的 gguf 文件。比如 Qwen3-235B-A22B-GGUF（里面有好几个模型:Q4_K_M, Q5_0,Q5_K_M, ...），你可以只下载其中 Q5_0 文件夹下所有文件，但是这时你也只能使用 Qwen3-235B-A22B-GGUF/Q5_0/Qwen3-235B-A22B-Q5_0-00001-of-00006.gguf 这个模型，你如果还需要使用 Qwen3-235B-A22B-GGUF 下的 Q5_K_M 模型你还需要继续下载 Q5_K_M 的文件。


e) 请在你的电脑资源管理器（Mac 电脑叫做“访达”）中找到“下载”文件夹，在“下载”文件夹当中应该会有“waterchat”，这时候依次打开以下文件夹“waterchat/resources/config”，此文件夹中应当有 config.txt 文件，打开这个文件，将这个文件中的 model_name_list=Qwen3-0.6B-GGUF 改为：model_name_list=Qwen3-0.6B-GGUF,Qwen3-1.7B-GGUF/Qwen3-1.7B-Q8_0.gguf。假如你是要新增第三个 AI 模型 Qwen3-32B-GGUF 了，那么 model_name_list 的形式应该是：model_name_list=Qwen3-0.6B-GGUF,Qwen3-1.7B-GGUF/Qwen3-1.7B-Q8_0.gguf,Qwen3-32B-GGUF/ Qwen3-32B-Q8_0.gguf。然后重新保存 config.txt 即可。**注意：英文逗号拼接，不要有空格，需要指定到 xxxx.gguf 文件名为止。**

f) 如果新增的模型有多个 gguf 文件，例如 Qwen3-235B-A22B-GGUF（里面有好几个模型:Q4_K_M, Q5_0,Q5_K_M, ...），比如 Qwen3-235B-A22B-GGUF /Q5_0 模型，它就有数个 gguf 文件：Qwen3-235B-A22B-Q5_0-00001-of-00006.gguf，Qwen3-235B-A22B-Q5_0-00002-of-00006.gguf，...等等，则需要指定第一个 **gguf** 文件名作为模型名称：Qwen3-235B-A22B-GGUF/Q5_0/Qwen3-235B-A22B-Q5_0-00001-of-00006.gguf 就是 Qwen3-235B-A22B-GGUF /Q5_0 模型的名称了。

g) 本步骤为**非必需步骤**。如果你的 AI 模型支持图片嵌入识别，那么在你的模型文件中应该包含有 **mmpoj-XXXXXX.gguf** 名字的文件。例如 Qwen3-VL-2B-Instruct-GGUF 模型就是一个支持图片嵌入识别的模型，它的模型文件中就包含了 mmpoj-Qwen3VL-2B-Instruct-F16.gguf 和 mmpoj-Qwen3VL-2B-Instruct-Q8_0.gguf 文件。如何你想要你的模型

在你问问题时支持上传图片给 AI 识别，那么本步骤才是必须要配置的。

假如你要添加 Qwen3-VL-2B-Instruct-GGUF/Qwen3VL-2B-Instruct-Q8_0.gguf 的图片嵌入识别功能，你除了需要按照步骤 a) → f) 逐步配置之外，现在还需要在你的电脑资源管理器（Mac 电脑叫做“访达”）中找到“下载”文件夹，在“下载”文件加当中应该会有“waterchat”，这时候依次打开以下文件夹“waterchat/resources/config”，此文件夹中应当有 config.txt 文件，打开这个文件，请单独增加一行，然后添加 **Qwen3-VL-2B-Instruct-GGUF/Qwen3VL-2B-Instruct-Q8_0.gguf:mmproj=Qwen3-VL-2B-Instruct-GGUF/mmproj-Qwen3VL-2B-Instruct-Q8_0.gguf** 或者 **Qwen3-VL-2B-Instruct-GGUF/Qwen3VL-2B-Instruct-Q8_0.gguf:mmproj=Qwen3-VL-2B-Instruct-GGUF/mmproj-Qwen3VL-2B-Instruct-F16.gguf**，取决于你想要哪一种图片映射配置文件，是 mmproj-Qwen3VL-2B-Instruct-Q8_0.gguf 还是 mmproj-Qwen3VL-2B-Instruct-F16.gguf。请特别注意红色部分的添加后缀名，请不要忘记这添加部分名字。



上图：g) 步骤中补充的 Qwen3-VL-2B-Instruct-GGUF 模型文件图。

- h) 重新打开本应用，应该就可以在 Help 页面下选择你新增的模型了。
- i) **强烈提醒：总之模型要制定到具体的：Qwen3-235B-A22B-GGUF/.../xxxx.gguf 文件为止。**

五. 问题解答

1.为什么安装应用只有一个 Qwen3-0.6B-GGUF 最简单的模型可以使用？

答：因为将程序封装为可直接安装执行的的应用的过程中，单个文件的大小不可以超过 2GB 的大小，Qwen3-0.6B-GGUF 的模型文件大约有 0.7GB，而仅仅比 Qwen3-0.6B-GGUF 大一点的 Qwen3-1.7B-GGUF 的模型参数单个文件最大有约 1.9GB，其他更大参数的模型的参数更是远远超过 2GB。应用本身太大下载过程中可能出现网络中断等等问题导致下载应用失败，产生不良的体验。

所以本应用只默认封装 Qwen3-0.6B-GGUF 模型。其他使用模型需要用户自行下载模型参数按

本文档步骤三中“三. 自行增加 AI 模型”提示，用户自行完成操作。

2.本应用支持自行增加哪些 AI 模型？

答：理论上所有支持 llama.cpp 加载的模型都可以支持。目前本应用关注的模型主要 Qwen3 GGUF 类型的大模型支持。

声明

如有描述不清、描述不符甚至描述有误的，敬请谅解。

如有描述与实际功能不符，请以应用的实际版本功能为准。

本操作手册描述不全面之处，敬请谅解。

本应用的相关测试已尽可能进行验证，如有遗漏甚至产生相关问题，敬请谅解。

本应用所依赖的运行环境以及所有代码相关外部库（依赖）、模型之相关权利义务均属原作者所有。

Author: Logan Qin

All Rights Reserved.